Bases de Données Réparties
Concepts et Techniques

Matthieu Exbrayat

ULP Strasbourg - Décembre 2007

Définition

- Une base de données répartie (distribuée) est une base de données logique dont les données sont distribuées sur plusieurs SGBD et visibles comme un tout.
- Les données sont échangées par messages
- Si les données sont dupliquées, on parle plutôt de BD répliquée

Principe fondamental

- « To the user, a distributed system should look exactly like a nondistributed system. »
  (C. Date, Introduction to Database Systems)
- Autonomie locale
- Egalité entre sites (pas de site « central »)
- Fonctionnement continu (pas d'interruption de service)
- Localisation transparente
- Fragmentation transparente
- Indépendance à la réplication
- Exécution de requêtes distribuées
- Gestion de transactions réparties
- Indépendance vis-à-vis du matériel
- Indépendance vis-à-vis du Système d'Exploitation
- Indépendance vis-à-vis du réseau
- Indépendance vis-à-vis du SGBD

- Autonomie locale
  - La BD locale est complète et autonome (intégrité, sécurité, gestion), elle peut évoluer indépendamment des autres (upgrades…)
- Egalité entre sites
  - Un site en panne ne doit pas empêcher le fonctionnement des autres sites (mais perturbations possibles)
- Fonctionnement continu
  - Distribution permet résistance aux fautes et aux pannes (en théorie)

- Localisation transparente
  - Accès uniforme aux données quel que soit leur site de stockage
- Fragmentation transparente
  - Des données (d'une même table) éparpillées doivent être vues comme un tout
- Indépendance à la réplication
  - Les données répliquées doivent être maintenues en cohérence (délai possible)

- Requêtes distribuées
  - L'exécution d'une requête peut être répartie (automatiquement) entre plusieurs sites (si les données sont réparties)
- Transactions réparties
  - Le mécanisme de transactions peut être réparti entre plusieurs sites (si …)
- Indépendance vis-à-vis du matériel
  - Le SGBD fonctionne sur les différentes plateformes utilisées

- Indépendance vis-à-vis du SE
  - Le SGBD fonctionne sur les différents SE…
- Indépendance vis-à-vis du réseau
  - Le SGBD est accessible à travers les différents types de réseau utilisés
- Indépendance vis-à-vis du SGBD
  - La base peut être distibuée sur des SGBD hétérogènes
  - En théorie…

Quelques termes équivoques…

- BD distribuée
  - Un schéma global
  - Les données sont réparties sur plusieurs sites, accessibles à partir du site central ou de tous les sites
- BD fédérée
  - Chaque site a son schéma local, pas forcément inclus entièrement dans le schéma global (il y a un site central)
- Système multi-bases
  - Pas de schéma global, pas de site central. Accès à (une partie des) données distantes.
- Mais il existe d'autres définitions !
  - Ex : fédérée = approche ascendante partielle …

Conception de BD répartie

- On ne met en place une BD répartie qu'en cas de réel besoin
  - Démarche de conception délicate
  - Gestion complexe
  - L'évolution du SI peut invalider la solution retenue…
- Des raisons valables :
  - Volumes de données, sites distants, etc.
  - Fusions de SI

Deux approches de conception

- Conception ascendante
  - Part de l'existant
  - Intègre bases locales dans schéma global

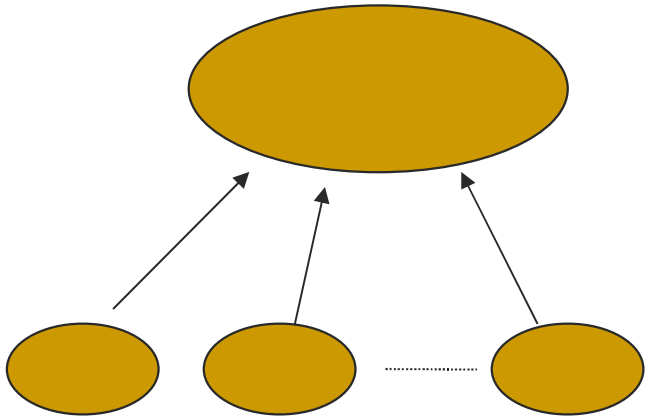

- Conception descendante
  - On part du schéma global
  - On le scinde en schémas locaux

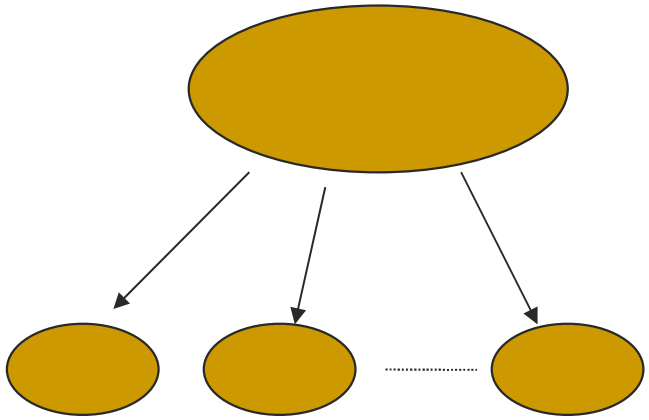

- Conception descendante
  - On part de zéro (nouvelle base)
  - Recherche de performance (pas forcément de répartition géographique)
  - Assez peu fréquent
- Conception ascendante
  - Distribution pré-existante
  - Nécessite consolidation, uniformisation (« réconciliation sémantique »)
    - Identifier les données semblables
    - Accorder leurs types, gérer leur cohérence…
    - Interfacer ou adapter les SGBD…
  - Ex : fusion, mise en place DW

Schémas d'une BD répartie

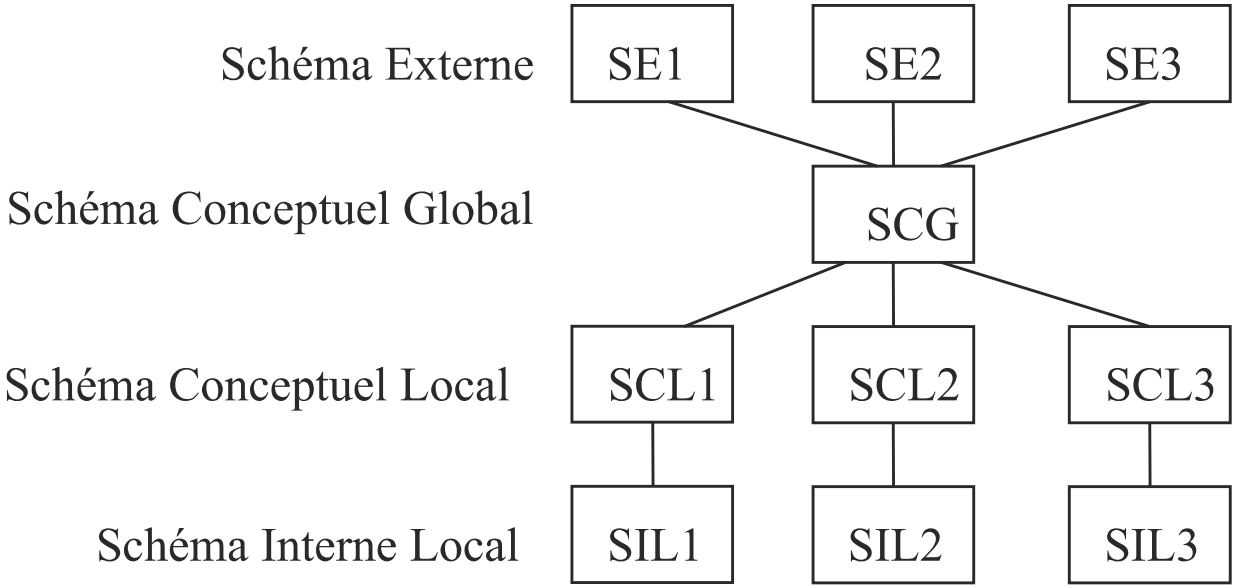

Fragmentation des données

- Fragmentation horizontale
  - Les tuples sont répartis

- Fragmentation verticale
  - Les tuples sont découpés et fragmentés
  - Nécessite colonne commune (clé ou unique) dupliquée

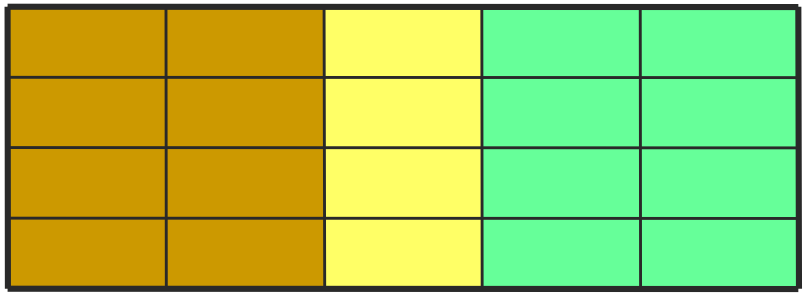

Fragmentation horizontale

- En conception descendante
  - Adéquation géographique
  - Recherche de performance (I/O, traitements)
- En conception ascendante
  - Des données comparables dans différentes bases
  - Pb : consolidation correcte (unicité des clés, types des attributs…)

Fragmentation verticale

- On projette la table sur des attributs différents suivant site.
- Comme frag. horizontale, peut correspondre à consolidation ou recherche de perf.
- La reconstruction des tuples doit être possible (et validée)
- Mêmes problèmes que f.h.

Frag. horizontale dérivée

- Placer deux tables en relation de manière à localiser les jointures
- Une des deux tables doit être fragmentée en fonction de l'autre (semi jointure)
- Plutôt en approche descendante
- Peut introduire des redondances

Mise en pratique de la fragmentation

- Historique : des SGBDs distribués
  - R*, etc.
  - Plutôt expérimental
- Dans les SGBD commerciaux actuels
  - Pas de fragmentation explicite au niveau du schéma
  - Assemblage = création de vue (ou de snapshot)
  - Distribution des données ?
    - Une solution = triggers

Mise en œuvre sous SQL (Assemblage)

- Frag. Horizontale
  - CREATE VIEW V1
    AS SELECT Table1.cle, Table1.attr1
    FROM Table1@site1
    UNION
    SELECT Table2.cle, Table2.attr1
    FROM Table2@site2

Mise en œuvre sous SQL (Assemblage)

- Frag. Verticale
  - CREATE VIEW V1
    AS SELECT Table1.cle, Table1.attr1,
    Table2.attr2
    FROM Table1@site1, Table2@site2
    WHERE Table1.cle=Table2.cle
- Remarque :
  - l'attribut de fragmentation n'est pas forcément la clé primaire…
  - En frag. verticale, il faut au néanmois que ce soit une clé

Requête répartie

- Les opérations précédentes (par exemple) accèdent à des données situées sur différents sites.
- Le SGBD gère les accès distants en répartissant la requête
  - Exécution distante de la sous requête
  - Récupération de données résultat
  - Assemblage local (requête en lecture)

Gestion de l'hétérogénéité

- Hétérogénéité « sans problème »
  - SE et réseau : géré par SGBD (si « bon » SGBD)
  - Version de SGBD : niveau de SGBD le plus ancien
- Hétérogénéité plus délicate
  - SGBD : pb des dialectes de SQL
  - passerelles entre SGBD
  - Ex : ODBC (au départ sous Windows mais porté sous d'autres OS)
  - Ex : passerelles propriétaires SGBD à SGBD

BDR comment ça marche

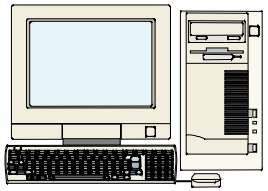

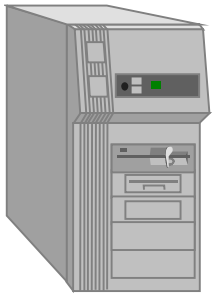

Application

Contrôleur sémantique

Requêtes réparties

Gestion de transactions

Schéma externe

SCG

Dictionnaire de répartition

Requêtes locales

Gestion de sous-transactions

SGBD

SCL

Journal des modifications

SIL

Communication Inter-sites

- Chaque SGBD dispose d'un démon permettant les connexions distantes, sur un mode client - serveur
  - *Listener (médiateur)*
- Chaque SGBD dispose d'une table des BDs accessibles
  - *Nom >> doit être unique !!!*
  - *Adresse*
  - *Protocole*
- Cette approche permet aussi un équilibrage de charge transparent…

Exemple : Oracle

- Permet la distribution et la réplication
- Assure une bonne transparence à différents niveaux

- Système de nommage simple
  - sales.france.europe.computers
- Accès BD distante : LINK
  - CREATE DATABASE LINK sales…
- Accès table distante : schéma.table@base
  - svc_maint.emp@sales.france.europe.computers
- Lien public, lien privé

Transparence

- Localisation : synonymes
  - CREATE PUBLIC SYNONYM employes FOR svc_maint.emp@sales.france.europe.computers
- Requêtes et transactions
- Opérations internes
- Réplication

Caractéristiques

- Autonomie des sites
  - Gestion indépendante, upgrades localisés…
- Sécurité
  - Les utilisateurs et leurs rôles doivent être connus sur chaque site accédé
  - Possibilité d'utiliser un Security Server
  - Encryptage
- Administration globale : enterprise manager

Mise en oeuvre en SQL (Insertion avec les triggers Oracle)

```
CREATE TRIGGER Tr1
INSTEAD OF INSERT on Table
BEGIN
IF :New.cle < 1000 THEN
    INSERT INTO Table1@site1(cle,attr1)
    VALUES(:New.cle,:New.attr);
ELSE
    INSERT INTO Table2@site2(cle,attr2)
VALUES (:New.cle,:New.attr);
END IF;
END;
```

Complément sur triggers

- Utilisables également pour update et delete (:New et :Old) pour
  - Suppression (:Old)
  - Modification hors attribut de distribution (:New)
  - Modification attribut de distribution (:New et :Old pour vérifier si bon site)
- Doit être écrit « à la main » par le dba…

Gestion des contraintes distribuées

- Types de contraintes
  - Domaine
  - Unicité
  - Intégrité référentielle
- Dans un SGBD centralisé, c'est bien géré
  - Dans la définition des tables (principalement)
- Le côté manuel de la distribution limite les possibilités de gestion des contraintes
  - Utilisation de vues >> pas de contraintes

Exemples

- Check / NOT NUL
  - Se gère par fragment
- Unicité
  - Gérable par fragment
  - Globalement ? Réplication OK, Fragmentation KO
  - Utilisation de trigger
  - Site maître pour numérotation >> perte autonomie
- Intégrité Référentielle
  - Pas géré en inter-bases
  - Réplication OK, Fragmentation KO
  - Utilisation trigger
- Ca devient vraiment lourd à gérer…

Liens BD : notions avancées

- 3 types de liens :
  - Connected user
    - Mode de base : même utilisateur en local et distant
    - Ce n'est pas nécessairement le créateur du lien
  - Current user
    - Si lien utilisé à partir de procédure, identification en temps que propriétaire de la procédure
    - Intérêt ?
  - Fixed user
    - Utilisateur fixe.
    - Intérêt ?

Exemples

- CREATE DATABASE LINK ventes.ulp.fr USING ‘ventes’;
- CREATE DATABASE LINK ventes.ulp.fr CONNECT TO scott IDENTIFIED BY tiger USING ‘ventes’;
- CREATE DATABASE LINK ventes.ulp.fr CONNECT TO CURRENT_USER USING ‘ventes’;
- Remarque : USING -> nom du service!

Liens BD : notions avancées

- Visibilité :
  - Public
    - Pratique si utilisé par un grand nombre d'utilisateurs
  - Private (défaut)
    - + sécurisé, accessible uniquement au propriétaire et à ses sous-programmes
  - Global
    - Accessible de n'importe quelle base, mais suppose une gestion centrale (directory server)

exemples

- CREATE PUBLIC DATABASE LINK ventes.ulp.fr
  USING ‘ventes’;
- CREATE PUBLIC DATABASE LINK ventes.ulp.fr
  CONNECT TO scott IDENTIFIED BY tiger
  USING ‘ventes’;
- CREATE PUBLIC DATABASE LINK ventes.ulp.fr
  CONNECT TO CURRENT_USER
  USING ‘ventes’;
- Différence avec privé ?

Opérations sur liens

- Fermeture
  - Utile si forte charge
  - ALTER SESSION CLOSE DATABASE LINK lien;
- Suppression
  - DROP DATABASE LINK lien

Infos utiles…

- Tables
  - DBA_DB_LINKS : tous les liens
  - ALL_DB_LINKS : tous ceux accessibles par l'utilisateur
  - USER_DB_LINKS : tous ceux qui lui appartiennent
  - V$DBLINK : tous les liens ouverts par la transaction
- Paramétrage
  - OPEN_LINKS : nombre de liens simultanés dans une même session (défaut 4, 0 = pas de limite)
  - (INIT.ORA)

Liens partagés

- Un lien peut être partagé par plusieurs utilisateurs
- Mot clé « shared »
- **CREATE SHARED DATABASE LINK nomlien** [CONNECT TO util IDENTIFIED BY passwd]| [CONNECT TO CURRENT_USER] **AUTHENTICATED BY schema IDENTIFIED BY passwd** [USING ‘service’]
- Authentification pour le lien, connexion au schéma distant suivant mode de connexion choisi
- Intérêt : si beaucoup de connexions, sinon surcoût (pooling)
- Peut être connecté vers serveur à processus dédiés ou partagés

Notion de nommage global

- Oracle peut utiliser le nommage global
  - Chaque base est identifiée par un nom et un domaine. Le nom complet doit être unique
  - Utile avec les liens, indispensable pour la réplication
- Paramétrage
  - GLOBAL_NAMES (INIT.ORA)

Manipuler les noms globaux

- SELECT NAME,VALUE FROM V $PARAMETER WHERE NAME=« db_domain »;
  - Modifier : dans INIT.ORA
- SELECT * FROM GLOBAL_NAME;
- ALTER DATABASE RENAME GLOBAL_NAME TO nom.domain;

Bases de données répliquées

- Ensemble de bases de données identiques, dont une appelée *copie maître* permet de créer les autres appelées *copies esclaves*.

- Techniques de mise en cohérence
  - Synchrone: la mise à jour des copies est faite dans la même transaction
  - Asynchrone: la mise à jour des copies est faite le plus tôt possible

Bases de données répliquées

- Alimentation d ’entrepôt de données

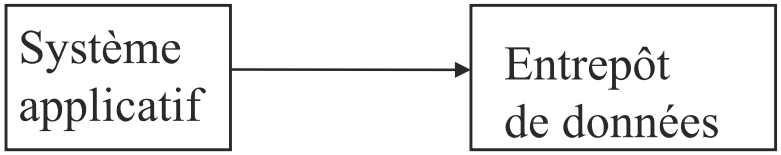

- Dissémination de données

- Consolidation de données

Bases de données répliquées

- **Découpage d'un processus par activité**

- **Accès délocalisé**

- **Systèmes 24h/2 4**

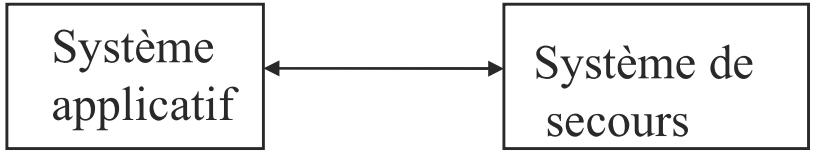

Bases de données répliquées

- **Réplication sans conflits**

  En évitant les mises à jour multiples (réplication asymétrique)

  - **Système maître unique**
    - **Alimentation des entrepôts de données**
    - **Dissémination d'information**
    - **Consolidation d'information**
  - **Système maître désigné en dynamique**
    - **Découpage d'un processus par activité**

- **Réplication avec résolution des conflits**

  Une règle de priorité permet de résoudre les conflits (r. symétrique)

  - **Systèmes maîtres multiples**
    - **Accès délocalisé**
    - **Système 24h/24**

Bases de données répliquées

- Copies maîtres multiples

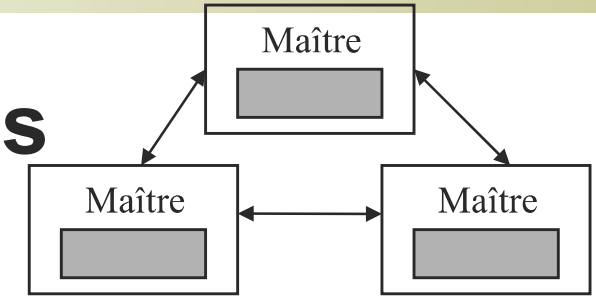

- Copies esclaves modifiables

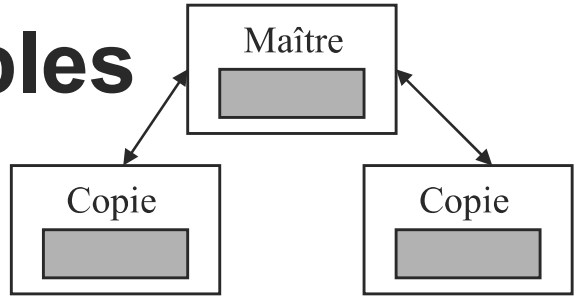

- Configuration hybride

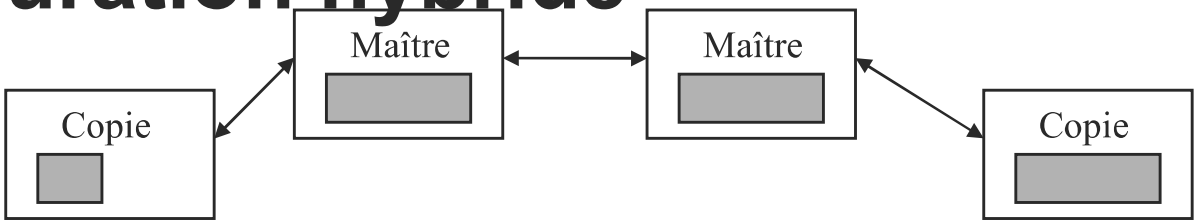

Réplication

- Réplication simple (maître-esclave, read only)
  - Snapshots
  - MAJ : complète ou incrémentale
  - Snapshots complexes : plusieurs tables, pas de MAJI
- Réplication avancée (multi maîtres, rw)
  - multimaître, hybride
  - réplication objet ou groupe
  - site et catalogue de réplication

Conflits d'accès

- Unicité, modif, suppression
  - Des méthodes dans les deux premiers cas
  - pour suppr, suggère l'utilisation d'un flag « suppr »

- Possession statique : une donnée $\in$ à un seul serveur
- Possession dynamique : les serveurs demandent l'exclusivité
- Possession partagée : les conflits éventuels sont gérés de manière asynchrone

- Gestion synchrone : synchro immédiate

Création d'une vue matérialisée

- CREATE MATERIALIZED VIEW nommv
  [TABLESPACE … STORAGE …]
  [REFRESH FAST|COMPLETE|FORCE
  START WITH sysdate
  NEXT sysdate+1 *// en jours…*
  WITH PRIMARY KEY *// si possible …*
  USING ROLLBACK SEGMENT …]
  AS
  SELECT…

Vue simple

- Rafraîchissement rapide possible
- Repose sur clé
  - WITH PRIMARY KEY
- Repose sur ROW ID
  - WITH ROW ID
- Repose sur une requête adaptée
  - sous requête de type exists
  - union

Des vues « simples »…

- CREATE MATERIALIZED VIEW info_produit REFRESH FAST AS
  SELECT * FROM info_produit ip
  WHERE id =10 AN EXISTS
  (SELECT * FROM descr_produit dp
  WHERE…)
  UNION
  …
- Cela reste rafraîchissable en fast !

Des vues plus complexes…

- Pas fast refresh si contient :
  - DISTINCT, UNIQUE
  - INTERSECT, MINUS, UNION ALL
  - CONNECT BY
  - Jointure
  - Agrégation
  - UNION si pas les mêmes types (ou requête complexe)
- Pour tester rafraîchissement rapide
  - DBMS_VIEW.EXPLAIN_MVIEW(‘vue’);

Compléments sur les V.M.

- pour que le REFRESH fonctionne il faut paramétrer Oracle en conséquence…
  - Noms globaux obligatoires
  - Utilisation d'un lien en fixed user
- Pour autoriser le fast refresh if faut créer un snapshot log sur la table source
  - CREATE SNAPSHOT LOG ON Table
    WITH PRIMARY KEY
    TABLESPACE ... STORAGE (…)

Refresh gérable par le biais de fonctions PL/SQL

- DBMS_REFRESH.REFRESH('vue');

Groupe de rafraîchissement

- DBMS_REFRESH.MAKE(
  name =>’nomgrp’,
  list=>’’,
  next_date=> SYSDATE,
  interval=> ‘SYSDATE+… ‘,
  implicit_destroy=> FALSE,
  rollback_seg => ‘’,
  push_deferred => TRUE,
  refresh_after_errors => FALSE);

- DBMS_REFRESH.ADD(
  name=>’nomgrp’,
  list=>’nomvue’,
  lax=TRUE);

Vues matérialisées modifiables

- Intérêt ?
- Ajouter « FOR UPDATE » avant le « AS SELECT… »
- Rattacher à un groupe de vues matérialisées

Groupe de vues matérialisées

- Simplification de l'administration
- D'autres avantages…
- Création du groupe :
  - DBMS_REPCAT.CREATE_MVIEW_REPGROUP(
    gname=>'nomgrp',
    master=>'base d'origine',
    propagation_mode=>'ASYNCHRONOUS');
- Ajout dans le groupe
  - DBMS_REPCAT.CREATE_MVIEW_REPOBJECT(
    gname=>'nomgrp',
    sname=>'schema',
    oname=>'nommv',
    type=>'SNAPSHOT',
    min_communication>='TRUE');

Privilèges

- ALTER ANY SNAPSHOT
- CREATE ANY SNAPSHOT
- DROP ANY SNAPSHOT
  - Plutôt pour le DBA…
- CREATE DATABASE LINK
  - Utile car permet d'utiliser les liens privés
- CREATE SNAPSHOT
  - permet ajout, modif et suppr
- CREATE VIEW
  - Permet gestion de vue sous-jacente au snapshot

Vues multi tiers

- On peut avoir des vues matérialisées qui reposent elles mêmes sur des vues matérialisées
- Contraintes : essentiellement utilisation des clés primaires.

Systèmes multi maîtres

- Intérêt :
  - Équilibrage de charge
  - Résistance aux pannes
  - Interopérabilité entre applications
- Cohérence ?
  - Synchrone : MAJ immédiate
  - Asynchrone : files d'attente (et d'erreur…)

Mise en oeuvre

- Rôles
  - Administrateur
    - Ajout de sites, mise en sommeil, etc.
  - Propagateur
    - Envoi des requêtes
  - Récepteur
    - Mise en œuvre des requêtes reçues

Structures

- Liens planifiés
  - Liens avec utilisateur fixe + planification des envois (transactions)
- Purge
- Groupe maître
  - Contient les objets répliqués
  - Il peut y en avoir plusieurs…
  - Notion de site de définition
- Site maîtres
  - Ajoutés sur le site de définition

Résolution de conflits

- Méthodes proposées par Oracle:
  - Plus récente modif (timestamp)
  - Réécriture
  - Max et min
  - Moyenne et somme
  - Estampillage
  - Priorité de groupe
  - Priorité de site

Résolution de conflit

- Plus récente modif
  - La plus récente est la bonne
  - (pas de lien entre valeurs)
  - Suppose datage uniforme
- Réécriture
  - Essentiellement pour mono maître

Résolution de conflit

- Additive
  - On ajoute la différence
  - OK pour transactions financières par ex.
- Moyenne
  - OK pour donnée évoluant vers moyenne
- Abandon
  - OK avec mono maître

Résolution de conflit

- Plus ancienne date
  - Utilisation limitée… (mono maître)
- Maximum, Minimum
  - Pour des données s'y prêtant
- Groupes prioritaires
  - Priorité suivant la valeur d'une colone donnée
- Site prioritaire

Autres types de conflits

- Insertion
  - Séquences
- Suppression
  - Colonne de suppression

Eviter les conflits

- Groupes de colonnes
  - On peut modifier sur deux groupes indépendants sans générer de conflit
- Site propriétaire
  - Granularité réglable
- Possession dynamique

Compléments sur la réplication

- Template de réplication
  - Pour simplifier réplication massive
  - Ex : copies sur machines nomades
  - Description des tables distribuées
- Réplication d'autres informations
  - Triggers
  - Types d'Objets
  - …